Dimostrazioni di Machine Learning — versione riorganizzata e completa

Questa dispensa riorganizza e migliora gli appunti forniti, con quattro obiettivi:

1. **notazione coerente** in tutto il testo;
2. **dimostrazioni passo passo**, senza salti logici;
3. **intuizione geometrica e statistica** accanto ai calcoli;
4. **correzione dei punti più facili da confondere** all'esame.

Convenzioni e notazione

Userò quasi sempre queste convenzioni:

- n: numero di campioni
- d: numero di feature
- $x_i \in \mathbb{R}^d$: i-esimo input
- y_i: i-esima etichetta / target
- $X \in \mathbb{R}^{n \times d}$: **design matrix**
- $\theta \in \mathbb{R}^d$: vettore dei parametri
- $\hat{y} = X\theta$: vettore delle predizioni
- $r = y - X\theta$: vettore dei residui

Quando serve l'intercetta, la assorbo nella matrice X aggiungendo una colonna di 1.

---

1. Predittore ottimale con diverse loss

L'idea generale è sempre la stessa: fissato un valore x, vogliamo scegliere una predizione z che minimizzi il **rischio condizionato**

$$\phi(z) = \mathbb{E}[\ell(z, Y) \mid X = x].$$

Il predittore ottimale è quindi

$$f^*(x) = \arg\min_z \mathbb{E}[\ell(z, Y) \mid X = x].$$

1.1 Perdita quadratica: il predittore ottimale è la media condizionata

Obiettivo

Dimostrare che, se

$$\ell(z, Y) = (z - Y)^2,$$

allora il predittore ottimale è

$$f^*(x) = \mathbb{E}[Y \mid X = x].$$

Dimostrazione passo passo

Fissiamo x e poniamo

$$\mu(x) = \mathbb{E}[Y \mid X = x].$$

Dobbiamo minimizzare

$$\phi(z) = \mathbb{E}[(z - Y)^2 \mid X = x].$$

Aggiungiamo e sottraiamo $\mu(x)$ dentro la parentesi:

$$z - Y = (z - \mu) + (\mu - Y).$$

Quindi

$$(z - Y)^2 = \big((z - \mu) + (\mu - Y)\big)^2.$$

Sviluppiamo il quadrato:

$$(z - Y)^2 = (z - \mu)^2 + (\mu - Y)^2 + 2(z - \mu)(\mu - Y).$$

Ora facciamo il valore atteso condizionato:

$$\phi(z) = \mathbb{E}[(z - \mu)^2 \mid X = x] + \mathbb{E}[(\mu - Y)^2 \mid X = x] + 2\mathbb{E}[(z - \mu)(\mu - Y) \mid X = x].$$

Osserviamo che $z - \mu$ è una costante rispetto a Y quando x è fissato. Quindi:

$$\phi(z) = (z - \mu)^2 + \mathbb{E}[(\mu - Y)^2 \mid X = x] + 2(z - \mu)\mathbb{E}[\mu - Y \mid X = x].$$

Ma

$$\mathbb{E}[\mu - Y \mid X = x] = \mu - \mathbb{E}[Y \mid X = x] = \mu - \mu = 0.$$

Allora il termine misto sparisce e resta

$$\phi(z) = (z - \mu)^2 + \mathbb{E}[(\mu - Y)^2 \mid X = x].$$

Il secondo termine non dipende da z. Per minimizzare $\phi(z)$, dobbiamo quindi minimizzare solo $(z - \mu)^2$, che è minimo in $z = \mu$.

Conclusione

$$f^*(x) = \mathbb{E}[Y \mid X = x].$$

Interpretazione

Con la loss quadratica, il miglior numero da predire è il **baricentro** della distribuzione condizionata di Y.

1.2 Perdita assoluta: il predittore ottimale è la mediana condizionata

Obiettivo

Dimostrare che, se

$$\ell(z, Y) = |z - Y|,$$

allora il predittore ottimale è una **mediana condizionata** di $Y \mid X = x$.

Dimostrazione passo passo

Fissiamo x e definiamo

$$\phi(z) = \mathbb{E}[|z - Y| \mid X = x].$$

Supponiamo per semplicità che $Y \mid X = x$ abbia densità $p(y \mid x)$. Allora

$$\phi(z) = \int_{-\infty}^{+\infty} |z - y|\, p(y \mid x)\, dy.$$

Poiché il valore assoluto cambia forma in $y = z$, separiamo l'integrale:

$$\phi(z) = \int_{-\infty}^{z} (z-y)p(y \mid x)\,dy + \int_{z}^{+\infty} (y-z)p(y \mid x)\,dy.$$

Deriviamo rispetto a z usando la regola di Leibniz.

Derivata del primo termine

$$\frac{d}{dz}\int_{-\infty}^{z} (z-y)p(y \mid x)\,dy = \int_{-\infty}^{z} 1 \cdot p(y \mid x)\,dy + (z-z)p(z \mid x).$$

Il termine al bordo è nullo, quindi resta

$$\int_{-\infty}^{z} p(y \mid x)\,dy = P(Y \leq z \mid X = x).$$

Derivata del secondo termine

$$\frac{d}{dz}\int_{z}^{+\infty} (y-z)p(y \mid x)\,dy = \int_{z}^{+\infty} (-1)\,p(y \mid x)\,dy - (z-z)p(z \mid x).$$

Anche qui il termine al bordo è nullo, quindi resta

$$-\int_{z}^{+\infty} p(y \mid x)\,dy = -P(Y \geq z \mid X = x).$$

Condizione di ottimalità

Mettiendo insieme i due pezzi,

$$\phi'(z) = P(Y \leq z \mid X = x) - P(Y \geq z \mid X = x).$$

Nel punto di minimo vogliamo $\phi'(z) = 0$, quindi

$$P(Y \leq z \mid X = x) = P(Y \geq z \mid X = x).$$

Questa è precisamente la caratterizzazione della **mediana**.

Conclusione

$$f^*(x) = \text{mediana di } Y \mid X = x.$$

Interpretazione

Con la loss assoluta non conta il "centro di massa" della distribuzione, ma il punto che lascia metà probabilità a sinistra e metà a destra.

1.3 Classificazione binaria: classificatore di Bayes

Obiettivo

Supponiamo $Y \in \{0, 1\}$. Vogliamo capire quale decisione minimizza il rischio condizionato.

Caso generale: loss con costi arbitrari

Se scegliamo l'azione $a \in \{0, 1\}$, il rischio condizionato è

$$R(a \mid x) = \sum_{y \in \{0,1\}} \ell(a, y) P(Y = y \mid X = x).$$

Quindi:

- se prediciamo 1,

$$R(1 \mid x) = \ell(1, 0) P(Y = 0 \mid x) + \ell(1, 1) P(Y = 1 \mid x);$$

- se prediciamo 0,

$$R(0 \mid x) = \ell(0, 0) P(Y = 0 \mid x) + \ell(0, 1) P(Y = 1 \mid x).$$

La regola ottimale è: predici 1 se $R(1 \mid x) \leq R(0 \mid x)$.

Sviluppiamo:

$$\ell(1, 0) P(Y = 0 \mid x) + \ell(1, 1) P(Y = 1 \mid x) \leq \ell(0, 0) P(Y = 0 \mid x) + \ell(0, 1) P(Y = 1 \mid x).$$

Riordiniamo i termini:

$$P(Y = 1 \mid x)\big(\ell(0, 1) - \ell(1, 1)\big) \geq P(Y = 0 \mid x)\big(\ell(1, 0) - \ell(0, 0)\big).$$

Se dividiamo per $P(Y = 0 \mid x)$ e per il denominatore positivo, otteniamo una regola di soglia:

$$\frac{P(Y = 1 \mid x)}{P(Y = 0 \mid x)} \geq \frac{\ell(1, 0) - \ell(0, 0)}{\ell(0, 1) - \ell(1, 1)}.$$

Caso particolare: 0-1 loss

Se la loss è quella standard di classificazione,

$$\ell(\hat{y}, y) = \mathbf{1}\{\hat{y} \neq y\},$$

allora:

- costo corretto $= 0$
- costo errore $= 1$

Quindi:

$$R(1 \mid x) = P(Y = 0 \mid x), \qquad R(0 \mid x) = P(Y = 1 \mid x).$$

Prediciamo 1 se

$$P(Y = 0 \mid x) \leq P(Y = 1 \mid x),$$

cioè

$$P(Y = 1 \mid x) \geq \frac{1}{2}.$$

Conclusione

Il classificatore ottimale è il **classificatore di Bayes**:

$$f^*(x) = \begin{cases} 1 & \text{se } P(Y = 1 \mid X = x) \geq 1/2, \\ 0 & \text{altrimenti.} \end{cases}$$

Interpretazione

Con loss 0-1, la decisione ottimale è "scegli la classe più probabile".

---

2. Regressione lineare semplice: trovare m e q

Studiamo il modello

$$\hat{y}_i = m x_i + q.$$

Vogliamo minimizzare la loss quadratica empirica

$$\hat{R}(m,q) = \frac{1}{n}\sum_{i=1}^{n}(y_i - mx_i - q)^2.$$

Poiché la funzione è derivabile, cerchiamo il minimo imponendo che il gradiente sia nullo.

2.1 Derivata rispetto a q

Calcoliamo

$$\frac{\partial \hat{R}}{\partial q} = \frac{1}{n}\sum_{i=1}^{n} 2(y_i - mx_i - q)(-1).$$

Porre la derivata uguale a zero equivale a

$$\sum_{i=1}^{n}(y_i - mx_i - q) = 0.$$

Separiamo i termini:

$$\sum y_i - m\sum x_i - \sum q = 0.$$

Dato che $\sum q = nq$,

$$\sum y_i - m\sum x_i - nq = 0.$$

Dividendo per n,

$$\bar{y} - m\bar{x} - q = 0,$$

quindi

$$\hat{q} = \bar{y} - m\bar{x}.$$

Interpretazione

La retta ottima passa sempre per il punto medio del dataset $(\bar{x}, \bar{y})$.

2.2 Derivata rispetto a m

Calcoliamo

$$\frac{\partial \hat{R}}{\partial m} = \frac{1}{n} \sum_{i=1}^{n} 2(y_i - mx_i - q)(-x_i).$$

Poniamo la derivata uguale a zero:

$$\sum_{i=1}^{n} x_i(y_i - mx_i - q) = 0.$$

Sostituiamo $q = \bar{y} - m\bar{x}$:

$$\sum x_i\big(y_i - mx_i - (\bar{y} - m\bar{x})\big) = 0.$$

Sviluppiamo:

$$\sum x_i\big((y_i - \bar{y}) - m(x_i - \bar{x})\big) = 0.$$

Portiamo fuori m:

$$\sum x_i(y_i - \bar{y}) - m \sum x_i(x_i - \bar{x}) = 0.$$

Da cui

$$m = \frac{\sum x_i(y_i - \bar{y})}{\sum x_i(x_i - \bar{x})}.$$

Questa formula è corretta, ma si può semplificare in una forma più standard.

2.3 Forma standard della pendenza

Usiamo il fatto che

$$\sum_{i=1}^{n} (y_i - \bar{y}) = 0.$$

Allora

$$\sum x_i(y_i - \bar{y}) = \sum (x_i - \bar{x})(y_i - \bar{y}) + \bar{x} \sum (y_i - \bar{y}) = \sum (x_i - \bar{x})(y_i - \bar{y}).$$

Analogamente,

$$\sum x_i(x_i - \bar{x}) = \sum (x_i - \bar{x})^2.$$

Quindi la formula standard è

$$\hat{m} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}.$$

E quindi

$$\hat{q} = \bar{y} - \hat{m}\bar{x}.$$

Forma statistica

$$\hat{m} = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)}.$$

---

3. Regressione lineare in forma matriciale e OLS

Passiamo al modello lineare generale

$$\hat{y} = X\theta,$$

dove

- $X \in \mathbb{R}^{n \times d}$ è la design matrix;
- $\theta \in \mathbb{R}^d$ è il vettore dei parametri;
- $y \in \mathbb{R}^n$ è il vettore dei target.

Vogliamo minimizzare

$$\hat{R}(\theta) = \frac{1}{n} \|y - X\theta\|_2^2.$$

3.1 Espansione della loss

Usiamo la definizione di norma quadratica:

$$\|y - X\theta\|_2^2 = (y - X\theta)^T (y - X\theta).$$

Sviluppiamo:

$$(y - X\theta)^T (y - X\theta) = y^T y - y^T X\theta - \theta^T X^T y + \theta^T X^T X\theta.$$

Osserviamo che $y^T X\theta$ è uno scalare, quindi coincide con il suo trasposto:

$$y^T X\theta = \theta^T X^T y.$$

Allora

$$\hat{R}(\theta) = \frac{1}{n}\big(y^T y - 2\theta^T X^T y + \theta^T X^T X\theta\big).$$

3.2 Gradiente e equazioni normali

Deriviamo rispetto a θ:

- $\nabla_\theta(y^T y) = 0$, perché non dipende da θ;
- $\nabla_\theta(-2\theta^T X^T y) = -2X^T y$;
- $\nabla_\theta(\theta^T X^T X\theta) = 2X^T X\theta$.

Quindi

$$\nabla\hat{R}(\theta) = \frac{1}{n}\big(-2X^T y + 2X^T X\theta\big).$$

Ponendo il gradiente uguale a zero:

$$X^T X\theta = X^T y.$$

Queste sono le **equazioni normali**.

Se $X^T X$ è invertibile, allora

$$\hat{\theta} = (X^T X)^{-1} X^T y.$$

Questa è la soluzione **OLS (Ordinary Least Squares)**.

3.3 Perché compare X^T?

Questa è una domanda d'esame molto frequente.

La design matrix **non è "trasposta di suo"**. La trasposta compare per due motivi:

1. quando sviluppi il quadrato $(y - X\theta)^T(y - X\theta)$;
2. quando imponi la condizione geometrica di ortogonalità dei residui.

Più precisamente, al minimo il residuo

$$r = y - X\hat{\theta}$$

deve essere ortogonale a tutte le colonne di X. In forma matriciale:

$$X^T r = 0.$$

Sostituendo r,

$$X^T(y - X\hat{\theta}) = 0 \quad \Longrightarrow \quad X^T X\hat{\theta} = X^T y.$$

Quindi X^T compare perché "trasporta" l'informazione dallo spazio delle osservazioni allo spazio delle feature, e perché codifica l'ortogonalità del residuo alle colonne di X.

---

4. Interpretazione geometrica: proiezione ortogonale

Una delle letture più importanti di OLS è geometrica.

Il vettore $\hat{y} = X\hat{\theta}$ appartiene allo spazio generato dalle colonne di X, cioè

$$\hat{y} \in \mathrm{span}(X).$$

L'OLS sceglie il punto di $\mathrm{span}(X)$ più vicino a y in norma euclidea.

In altre parole, $\hat{y}$ è la **proiezione ortogonale** di y sul sottospazio $\mathrm{span}(X)$.

4.1 Matrice di proiezione

Definiamo

$$P = X(X^T X)^{-1} X^T.$$

Allora

$$\hat{y} = Py.$$

Vogliamo dimostrare che P è una proiezione ortogonale.

4.2 Prima proprietà: ogni vettore nello span resta invariato

Sia $v \in \text{span}(X)$. Allora esiste λ tale che

$$v = X\lambda.$$

Applichiamo P:

$$Pv = X(X^T X)^{-1} X^T (X\lambda).$$

Raggruppiamo i termini:

$$Pv = X(X^T X)^{-1}(X^T X)\lambda = XI\lambda = X\lambda = v.$$

Quindi P lascia invariati i vettori che stanno già nello spazio.

4.3 Seconda proprietà: ogni vettore ortogonale allo span viene mandato a zero

Sia u tale che $u \perp \text{span}(X)$. Questo equivale a dire

$$X^T u = 0.$$

Allora

$$Pu = X(X^T X)^{-1} X^T u = X(X^T X)^{-1} 0 = 0.$$

Quindi P annulla i vettori ortogonali allo spazio.

4.4 Conclusione geometrica

Le due proprietà precedenti caratterizzano una proiezione ortogonale. Quindi

$$\hat{y} = Py$$

è la proiezione ortogonale di y su $\text{span}(X)$.

Conseguenza chiave

Il residuo

$$r = y - \hat{y}$$

è ortogonale allo spazio generato dalle colonne di X, cioè

$$X^T r = 0.$$

Questa è esattamente la stessa informazione contenuta nelle equazioni normali.

---

5. Ottimalità di OLS e Hessiana

Per capire perché il punto trovato è davvero un minimo globale, guardiamo la derivata seconda.

Partiamo da

$$\hat{R}(\theta) = \frac{1}{2n}\|X\theta - y\|_2^2.$$

Uso il fattore $1/2$ solo per semplificare le derivate.

5.1 Gradiente

$$\nabla \hat{R}(\theta) = \frac{1}{n} X^T (X\theta - y).$$

5.2 Hessiana

Derivando ancora rispetto a θ,

$$H(\theta) = \nabla^2 \hat{R}(\theta) = \frac{1}{n} X^T X.$$

Questa Hessiana non dipende nemmeno da θ: è costante.

5.3 Perché è semidefinita positiva

Per dimostrare che H è semidefinita positiva, prendiamo un vettore arbitrario $v \in \mathbb{R}^d$ e calcoliamo

$$v^T H v = \frac{1}{n} v^T X^T X v.$$

Osserviamo che

$$v^T X^T = (Xv)^T.$$

Quindi

$$v^T H v = \frac{1}{n} (Xv)^T (Xv) = \frac{1}{n} \|Xv\|_2^2 \geq 0.$$

Poiché è sempre non negativo, H è semidefinita positiva.

Conclusione

La funzione di costo è **convessa**. Quindi ogni minimo locale è anche un **minimo globale**.

Se inoltre $X^T X$ è definita positiva (per esempio se le colonne di X sono linearmente indipendenti), il minimo è unico.

---

6. Proprietà statistiche di OLS

Assumiamo il modello lineare corretto

$$y = X\theta^* + \varepsilon,$$

dove

- θ^* è il parametro vero;
- ε è il rumore con
$$\mathbb{E}[\varepsilon] = 0, \qquad \mathbb{E}[\varepsilon\varepsilon^T] = \sigma^2 I.$$

6.1 Correttezza (unbiasedness) di OLS

Vogliamo mostrare che

$$\mathbb{E}[\hat{\theta}] = \theta^*.$$

Partiamo dalla formula di OLS:

$$\hat{\theta} = (X^T X)^{-1} X^T y.$$

Sostituiamo $y = X\theta^* + \varepsilon$:

$$\hat{\theta} = (X^T X)^{-1} X^T (X\theta^* + \varepsilon).$$

Distribuiamo:

$$\hat{\theta} = (X^T X)^{-1} X^T X\theta^* + (X^T X)^{-1} X^T \varepsilon.$$

Il primo termine si semplifica:

$$\hat{\theta} = \theta^* + (X^T X)^{-1} X^T \varepsilon.$$

Ora facciamo il valore atteso:

$$\mathbb{E}[\hat{\theta}] = \theta^* + (X^T X)^{-1} X^T \mathbb{E}[\varepsilon].$$

Poiché $\mathbb{E}[\varepsilon] = 0$,

$$\mathbb{E}[\hat{\theta}] = \theta^*.$$

Conclusione

OLS è **unbiased**: in media non introduce errore sistematico sui parametri.

6.2 Varianza dello stimatore OLS

Vogliamo calcolare

$$\mathrm{Var}(\hat{\theta}) = \mathbb{E}\big[(\hat{\theta} - \theta^*)(\hat{\theta} - \theta^*)^T\big].$$

Dalla formula appena ricavata,

$$\hat{\theta} - \theta^* = (X^T X)^{-1} X^T \varepsilon.$$

Allora

$$\mathrm{Var}(\hat{\theta}) = \mathbb{E}\Big[\big((X^T X)^{-1} X^T \varepsilon\big)\big((X^T X)^{-1} X^T \varepsilon\big)^T\Big].$$

Ora usiamo la regola del trasposto $(ABC)^T = C^T B^T A^T$:

$$\big((X^T X)^{-1} X^T \varepsilon\big)^T = \varepsilon^T X \big((X^T X)^{-1}\big)^T.$$

Poiché $X^T X$ è simmetrica, anche la sua inversa è simmetrica:

$$\big((X^T X)^{-1}\big)^T = (X^T X)^{-1}.$$

Quindi

$$\mathrm{Var}(\hat{\theta}) = \mathbb{E}\Big[(X^T X)^{-1} X^T \varepsilon \varepsilon^T X (X^T X)^{-1}\Big].$$

Portiamo fuori dall'aspettativa tutto ciò che è deterministico:

$$\mathrm{Var}(\hat{\theta}) = (X^T X)^{-1} X^T \mathbb{E}[\varepsilon \varepsilon^T] X (X^T X)^{-1}.$$

Usiamo l'ipotesi $\mathbb{E}[\varepsilon \varepsilon^T] = \sigma^2 I$:

$$\mathrm{Var}(\hat{\theta}) = (X^T X)^{-1} X^T (\sigma^2 I) X (X^T X)^{-1}.$$

Portiamo fuori σ^2:

$$\mathrm{Var}(\hat{\theta}) = \sigma^2 (X^T X)^{-1} X^T X (X^T X)^{-1}.$$

Semplificando,

$$\mathrm{Var}(\hat{\theta}) = \sigma^2 (X^T X)^{-1}.$$

Interpretazione

- più rumore (σ^2 alto) $\Rightarrow$ più incertezza;
- più informazione nei dati ($X^T X$ grande) $\Rightarrow$ varianza più piccola.

---

7. Scomposizione del rischio per la regressione lineare

Supponiamo ancora che il modello vero sia

$$Y = \phi(X)^T \theta^* + \varepsilon,$$

con $\mathbb{E}[\varepsilon \mid X] = 0$ e $\mathrm{Var}(\varepsilon \mid X) = \sigma^2$.

Definiamo il rischio di un parametro θ come

$$R(\theta) = \mathbb{E}\big[(\phi(X)^T \theta - Y)^2\big].$$

Vogliamo dimostrare

$$R(\theta) = (\theta - \theta^*)^T \Sigma (\theta - \theta^*) + \sigma^2,$$

dove

$$\Sigma = \mathbb{E}[\phi(X)\phi(X)^T].$$

7.1 Dimostrazione passo passo

Sostituiamo $Y = \phi(X)^T \theta^* + \varepsilon$:

$$R(\theta) = \mathbb{E}\Big[\big(\phi(X)^T \theta - \phi(X)^T \theta^* - \varepsilon\big)^2\Big].$$

Raggruppiamo:

$$R(\theta) = \mathbb{E}\Big[\big(\phi(X)^T (\theta - \theta^*) - \varepsilon\big)^2\Big].$$

Sviluppiamo il quadrato:

$$R(\theta) = \mathbb{E}\Big[(\phi(X)^T (\theta - \theta^*))^2 + \varepsilon^2 - 2\phi(X)^T (\theta - \theta^*)\varepsilon\Big].$$

Separiamo i tre termini.

Primo termine

$$(\phi(X)^T(\theta-\theta^*))^2 = (\theta-\theta^*)^T\phi(X)\phi(X)^T(\theta-\theta^*).$$

Prendendo il valore atteso,

$$\mathbb{E}\big[(\phi(X)^T(\theta-\theta^*))^2\big] = (\theta-\theta^*)^T\mathbb{E}[\phi(X)\phi(X)^T](\theta-\theta^*) = (\theta-\theta^*)^T\Sigma(\theta-\theta^*).$$

Secondo termine

$$\mathbb{E}[\varepsilon^2] = \sigma^2.$$

Terzo termine

Poiché $\mathbb{E}[\varepsilon \mid X] = 0$,

$$\mathbb{E}\big[\phi(X)^T(\theta-\theta^*)\varepsilon\big] = 0.$$

Quindi il termine incrociato scompare.

Conclusione

$$R(\theta) = (\theta-\theta^*)^T\Sigma(\theta-\theta^*) + \sigma^2.$$

7.2 Interpretazione

Il rischio ha due pezzi:

1. **errore di stima / approssimazione**

   $$(\theta-\theta^*)^T\Sigma(\theta-\theta^*)$$

   che dipende da quanto siamo lontani dal parametro ottimo;

2. **rumore irriducibile**

   $$\sigma^2,$$

   che non possiamo eliminare nemmeno con il modello perfetto.

---

8. Overfitting, bias-variance e Ridge Regression

Quando il modello è troppo flessibile rispetto ai dati disponibili, può adattarsi anche al rumore del training set: questo è l'**overfitting**.

8.1 Bias e varianza: idea intuitiva

- **Bias alto**: il modello è troppo semplice e sbaglia in modo sistematico.
- **Varianza alta**: il modello cambia molto se cambiano i dati di training.

Aumentando la complessità del modello, in generale:

- il bias tende a scendere;
- la varianza tende a salire.

L'overfitting è proprio il regime in cui la varianza domina.

8.2 Ridge Regression

Per combattere l'overfitting, aggiungiamo una penalizzazione L_2:

$$J(\theta) = \frac{1}{n}\|y - X\theta\|_2^2 + \lambda\|\theta\|_2^2, \qquad \lambda \geq 0.$$

Calcolo del gradiente

$$\nabla J(\theta) = \frac{2}{n}X^T(X\theta - y) + 2\lambda\theta.$$

Ponendo il gradiente uguale a zero,

$$\frac{1}{n}X^TX\theta - \frac{1}{n}X^Ty + \lambda\theta = 0.$$

Moltiplichiamo per n:

$$X^TX\theta - X^Ty + n\lambda\theta = 0.$$

Equivalentemente, assorbendo il fattore n dentro λ se la convenzione del corso lo fa, si ottiene la forma più comune

$$(X^TX + \lambda I)\theta = X^Ty.$$

Quindi

$$\hat{\theta}_{\text{ridge}} = (X^T X + \lambda I)^{-1} X^T y.$$

Perché aiuta

La matrice $X^T X + \lambda I$ è più stabile numericamente e, per $\lambda > 0$, risulta invertibile anche in situazioni problematiche in cui $X^T X$ è singolare o quasi singolare.

Effetto statistico

Ridge introduce un po' di bias, ma riduce la varianza. Spesso il bilanciamento migliora l'errore di generalizzazione.

---

9. Complessità computazionale della soluzione OLS

La soluzione chiusa è

$$\hat{\theta} = (X^T X)^{-1} X^T y.$$

Supponiamo $X \in \mathbb{R}^{n \times d}$.

9.1 Costo di $X^T X$

X^T è $d \times n$, quindi $X^T X$ è $d \times d$.

Il costo della moltiplicazione è

$$O(nd^2).$$

9.2 Costo dell'inversione

Invertire una matrice $d \times d$ costa, in prima approssimazione,

$$O(d^3).$$

9.3 Costo di $X^T y$

La moltiplicazione matrice-vettore costa

$$O(nd).$$

9.4 Complessità totale

$$O(nd^2 + d^3).$$

Conseguenza pratica

Se d è molto grande, il termine d^3 può diventare proibitivo. Per questo si usano metodi iterativi come il **Gradient Descent**.

---

10. Gradient Descent per la regressione lineare

Partiamo dalla loss

$$\hat{R}(\theta) = \frac{1}{2n}\|X\theta - y\|_2^2.$$

10.1 Gradiente

Abbiamo già visto che

$$\nabla \hat{R}(\theta) = \frac{1}{n} X^T (X\theta - y).$$

10.2 Aggiornamento

La regola del Gradient Descent è

$$\theta_{t+1} = \theta_t - \gamma_t \nabla \hat{R}(\theta_t),$$

quindi

$$\theta_{t+1} = \theta_t - \frac{\gamma_t}{n} X^T (X\theta_t - y).$$

Qui γ_t è il **learning rate**.

10.3 Perché converge al minimo globale

Lo abbiamo già visto con l'Hessiana:

$$\nabla^2 \hat{R}(\theta) = \frac{1}{n} X^T X \succeq 0.$$

La loss è convessa, quindi non ci sono minimi locali sbagliati. Con uno step size adeguato, Gradient Descent converge al minimo globale.

10.4 Interpretazione dell'Hessiana e condition number

Se $H = \frac{1}{n} X^T X$, gli autovalori di H controllano la curvatura della loss.

- Se gli autovalori sono ben bilanciati, la valle è "rotonda" e la convergenza è veloce.
- Se il rapporto tra autovalore massimo e minimo è grande, la valle è stretta e allungata: il Gradient Descent zigzaga e converge lentamente.

Questo rapporto è il **condition number**

$$\kappa = \frac{L}{\mu},$$

dove L è il massimo autovalore e μ il minimo positivo.

---

11. Stochastic Gradient Descent (SGD)

Il Gradient Descent batch usa tutto il dataset ad ogni iterazione. L'SGD usa invece un solo esempio casuale o un mini-batch.

11.1 Gradiente vero

Il gradiente della loss empirica può essere scritto come media dei gradienti dei singoli punti:

$$\nabla \hat{R}(\theta) = \frac{1}{n} \sum_{i=1}^{n} (\phi(x_i)^T \theta - y_i) \phi(x_i).$$

11.2 Stimatore stocastico

Scegliamo un indice i uniformemente a caso e definiamo

$$\tilde{g}(\theta) = (\phi(x_i)^T\theta - y_i)\phi(x_i).$$

Questo è un gradiente rumoroso, ma molto economico da calcolare.

11.3 Perché è unbiased

Calcoliamo il valore atteso rispetto alla scelta casuale dell'indice:

$$\mathbb{E}[\tilde{g}(\theta)] = \sum_{j=1}^{n} P(i = j)\,(\phi(x_j)^T\theta - y_j)\phi(x_j).$$

Poiché la scelta è uniforme, $P(i = j) = 1/n$. Quindi

$$\mathbb{E}[\tilde{g}(\theta)] = \frac{1}{n}\sum_{j=1}^{n}(\phi(x_j)^T\theta - y_j)\phi(x_j) = \nabla\hat{R}(\theta).$$

Conclusione

L'SGD è uno stimatore **corretto (unbiased)** del gradiente vero: in media punta nella direzione giusta.

---

12. Logistic Regression e Maximum Likelihood Estimation

La Logistic Regression non nasce da una loss quadratica, ma da un **modello probabilistico**.

Per $Y \in \{0, 1\}$, assumiamo

$$P(Y = 1 \mid x) = \sigma(\theta^T\phi(x)) = \frac{1}{1 + e^{-\theta^T\phi(x)}}.$$

Chiamiamo

$$p_i = P(Y = 1 \mid x_i) = \sigma(\theta^T\phi(x_i)).$$

Allora

$$P(Y = 0 \mid x_i) = 1 - p_i.$$

12.1 Perché è collegata alla MLE

Dato x_i, la variabile Y_i viene modellata come una Bernoulli di parametro p_i:

$$Y_i \mid x_i \sim \text{Bernoulli}(p_i).$$

Per una variabile Bernoulli, la probabilità del valore osservato $y_i \in \{0, 1\}$ si scrive in forma compatta come

$$P(Y_i = y_i \mid x_i) = p_i^{y_i}(1 - p_i)^{1-y_i}.$$

Assumendo indipendenza dei campioni, la likelihood dell'intero dataset è

$$L(\theta) = \prod_{i=1}^{n} p_i^{y_i}(1 - p_i)^{1-y_i}.$$

La **Maximum Likelihood Estimation** sceglie θ che massimizza $L(\theta)$.

12.2 Perché si usa il log-likelihood

Massimizzare un prodotto è scomodo. Applichiamo il logaritmo:

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^{n} \Big(y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big).$$

Poiché il logaritmo è strettamente crescente, massimizzare L o ℓ è equivalente.

12.3 Perché sembrano esistere due obiettivi diversi

In pratica si vedono due formulazioni:

Formulazione statistica

$$\max_{\theta} \ell(\theta).$$

Formulazione di ottimizzazione / machine learning

$$\min_{\theta} -\ell(\theta).$$

La quantità

$$-\ell(\theta) = -\sum_{i=1}^{n} \Big(y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big)$$

si chiama:

- **negative log-likelihood**
- **log-loss**
- **binary cross-entropy**

Sono tre nomi per lo stesso oggetto.

Messaggio da ricordare

Non ci sono due problemi diversi: è lo **stesso problema**, scritto una volta come massimizzazione e una volta come minimizzazione.

12.4 Perché non si ottimizza direttamente l'accuracy

L'accuracy dipende da una soglia e non è liscia. Piccole variazioni di probabilità possono non cambiare nulla o cambiare tutto di colpo.

La log-loss invece:

- è continua;
- è derivabile;
- penalizza molto le predizioni sbagliate ma molto sicure.

Per questo è adatta all'ottimizzazione con gradient methods.

---

13. Gradiente e concavità della log-likelihood logistica

13.1 Derivata della sigmoide

La sigmoide è

$$\sigma(z) = \frac{1}{1+e^{-z}}.$$

Deriviamo:

$$\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2}.$$

Riscriviamo il risultato in forma elegante. Notiamo che

$$\sigma(z) = \frac{1}{1+e^{-z}}, \qquad 1-\sigma(z) = \frac{e^{-z}}{1+e^{-z}}.$$

Moltiplicandole,

$$\sigma(z)(1-\sigma(z)) = \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} = \frac{e^{-z}}{(1+e^{-z})^2} = \sigma'(z).$$

Quindi la formula da ricordare è

$$\sigma'(z) = \sigma(z)(1-\sigma(z)).$$

13.2 Gradiente del log-likelihood

Per comodità poniamo $h_\theta(x_i) = p_i = \sigma(\theta^T \phi(x_i))$.

Il log-likelihood è

$$\ell(\theta) = \sum_{i=1}^{n} \Big(y_i \log p_i + (1-y_i)\log(1-p_i) \Big).$$

Derivando rispetto a θ, si ottiene

$$\nabla \ell(\theta) = \sum_{i=1}^{n} (y_i - p_i)\phi(x_i).$$

In forma matriciale:

$$\nabla \ell(\theta) = \Phi^T (y-p),$$

dove $p = (p_1, \ldots, p_n)^T$.

Se invece minimizziamo la negative log-likelihood, il gradiente cambia segno:

$$\nabla(-\ell(\theta)) = \Phi^T(p - y).$$

13.3 Hessiana e concavità

Derivando ancora, si ottiene

$$H(\theta) = \nabla^2 \ell(\theta) = -\Phi^T W \Phi,$$

dove W è la matrice diagonale

$$W = \mathrm{diag}(p_i(1 - p_i)).$$

Poiché \$0$\leq p_i(1 - p_i)\$, lamatriceW$ è semidefinita positiva.

Prendiamo un vettore arbitrario v. Allora

$$v^T H v = -v^T \Phi^T W \Phi v = -(\Phi v)^T W (\Phi v).$$

Chiamiamo $u = \Phi v$. Allora

$$v^T H v = -u^T W u = -\sum_{i=1}^{n} w_i u_i^2 \leq 0.$$

Quindi l'Hessiana è semidefinita **negativa**.

Conclusione

Il log-likelihood $\ell(\theta)$ è **concavo**. Dunque ha un unico massimo globale (a meno di degenerazioni).

Se invece consideriamo la negative log-likelihood, la Hessiana cambia segno e diventa semidefinita positiva: la loss è convessa.

---

14. Legame tra cross-entropy e KL divergence

Sia p la distribuzione vera e q_θ quella predetta dal modello.

La KL divergence è

$$\mathrm{KL}(p\|q_\theta) = \sum_i p_i \log \frac{p_i}{q_{\theta,i}}.$$

Sviluppiamo:

$$\mathrm{KL}(p\|q_\theta) = \sum_i p_i \log p_i - \sum_i p_i \log q_{\theta,i}.$$

Il primo termine non dipende da θ. Quindi minimizzare la KL rispetto a θ equivale a minimizzare

$$-\sum_i p_i \log q_{\theta,i},$$

che è precisamente la **cross-entropy**.

Perciò, in classificazione probabilistica:

- massimizzare la log-likelihood;
- minimizzare la negative log-likelihood;
- minimizzare la cross-entropy;
- minimizzare la KL dalla distribuzione vera alla distribuzione del modello

sono tutte formulazioni equivalenti, a meno di costanti additive.

---

15. Softmax Regression: gradiente

Per il caso multiclasse con K classi, definiamo per la classe k:

$$s_k(x) = \phi(x)^T \theta^{(k)}.$$

La Softmax definisce

$$\hat{P}^{(k)}(x) = \frac{e^{s_k(x)}}{\sum_{j=1}^{K} e^{s_j(x)}}.$$

Usiamo etichette one-hot $y_i^{(k)} \in \{0,1\}$, con $\sum_k y_i^{(k)} = 1$.

Il log-likelihood è

$$L(\theta) = \sum_{i=1}^{n} \sum_{k=1}^{K} y_i^{(k)} \log \hat{P}^{(k)}(x_i).$$

15.1 Derivata della Softmax rispetto agli score

Per prima cosa deriviamo $\hat{P}^{(l)}$ rispetto a s_k.

Caso $l = k$

$$\frac{\partial \hat{P}^{(k)}}{\partial s_k} = \hat{P}^{(k)}(1 - \hat{P}^{(k)}).$$

Caso $l \neq k$

$$\frac{\partial \hat{P}^{(l)}}{\partial s_k} = -\hat{P}^{(l)} \hat{P}^{(k)}.$$

15.2 Gradiente rispetto a $\theta^{(k)}$

Applicando la chain rule, si ottiene il risultato fondamentale:

$$\nabla_{\theta^{(k)}} L(\theta) = \sum_{i=1}^{n} \big(y_i^{(k)} - \hat{P}^{(k)}(x_i)\big)\phi(x_i).$$

Questa formula è l'analogo multiclasse del gradiente logistico binario.

Messaggio importante

Anche qui la struttura è sempre la stessa:

$$\text{gradiente} = \text{errore} \times \text{input}.$$

---

16. Concavità della log-likelihood per Softmax

La dimostrazione completa è più tecnica, ma l'idea è questa: la Hessiana a blocchi della log-likelihood è semidefinita negativa.

Il modo elegante di vederlo è osservare che, per un singolo esempio, il termine quadratico può essere riscritto come l'opposto di una varianza, e quindi è sempre ≤ 0.

Conclusione finale

La log-likelihood Softmax è concava. Equivalentemente, la cross-entropy multiclasse è convessa.

---

17. Perceptron: teorema di convergenza

Assumiamo dati linearmente separabili. Esiste cioè un vettore θ^* con $\|\theta^*\| = 1$ tale che

$$y_i \, \theta^{*T} x_i \geq \gamma^* > 0 \quad \forall i.$$

Qui γ^* è il margine di separazione.

L'algoritmo del perceptron aggiorna:

$$\theta_{t+1} = \theta_t + y_i x_i$$

quando sbaglia sul punto (x_i, y_i).

Vogliamo mostrare che il numero di errori è finito.

17.1 Upper bound sulla norma

Se facciamo un aggiornamento,

$$\|\theta_{t+1}\|^2 = \|\theta_t + y_i x_i\|^2.$$

Sviluppiamo:

$$\|\theta_{t+1}\|^2 = \|\theta_t\|^2 + 2 y_i x_i^T \theta_t + \|x_i\|^2.$$

Nel caso classico del perceptron, l'aggiornamento avviene quando $y_i x_i^T \theta_t \leq 0$. Quindi

$$2 y_i x_i^T \theta_t \leq 0.$$

Se $R = \max_i \|x_i\|$, allora

$$\|\theta_{t+1}\|^2 \leq \|\theta_t\|^2 + R^2.$$

Dopo M errori,

$$\|\theta_M\|^2 \leq MR^2, \qquad \|\theta_M\| \leq \sqrt{M}\, R.$$

17.2 Lower bound sul prodotto con θ^*

Consideriamo

$$\theta^{*T}\theta_{t+1} = \theta^{*T}(\theta_t + y_i x_i) = \theta^{*T}\theta_t + y_i \theta^{*T} x_i.$$

Per definizione di margine,

$$y_i \theta^{*T} x_i \geq \gamma^*.$$

Quindi ogni aggiornamento aumenta il prodotto di almeno γ^*. Dopo M errori,

$$\theta^{*T}\theta_M \geq M\gamma^*.$$

17.3 Sandwich finale con Cauchy-Schwarz

Per Cauchy-Schwarz,

$$\theta^{*T}\theta_M \leq \|\theta^*\|\|\theta_M\| = \|\theta_M\|,$$

perché $\|\theta^*\| = 1$.

Usando i due bound ottenuti:

$$M\gamma^* \leq \|\theta_M\| \leq \sqrt{M}\, R.$$

Eleviamo al quadrato:

$$M^2(\gamma^*)^2 \leq MR^2.$$

Se $M > 0$, dividiamo per M:

$$M \leq \frac{R^2}{(\gamma^*)^2}.$$

Conclusione

Il numero di errori è finito: il perceptron converge in un numero di passi limitato.

---

18. SVM: dalla formulazione geometrica alla hinge loss

18.1 Hard margin

Se i dati sono separabili, vogliamo il separatore col margine massimo:

$$\min_{\theta} \frac{1}{2}\|\theta\|^2 \quad \text{soggetto a} \quad y_i\theta^T x_i \geq 1 \ \forall i.$$

Minimizzare $\|\theta\|^2$ equivale a massimizzare il margine geometrico.

18.2 Soft margin con variabili slack

Se i dati non sono perfettamente separabili, introduciamo slack $\xi_i \geq 0$:

$$\min_{\theta,\xi} \frac{1}{2}\|\theta\|^2 + C\sum_{i=1}^{n} \xi_i$$

soggetto a

$$y_i\theta^T x_i \geq 1 - \xi_i, \qquad \xi_i \geq 0.$$

18.3 Come nasce la hinge loss

Dal vincolo

$$y_i\theta^T x_i \geq 1 - \xi_i$$

otteniamo

$$\xi_i \geq 1 - y_i\theta^T x_i.$$

Insieme a $\xi_i \geq 0$, questo significa che ξ_i deve essere almeno il massimo tra queste due quantità:

$$\xi_i = \max\big(0,\, 1 - y_i \theta^T x_i\big).$$

Questa è esattamente la **hinge loss**:

$$(1 - y_i \theta^T x_i)_+.$$

Sostituendo, otteniamo la formulazione unconstrained:

$$J(\theta) = \frac{1}{2}\|\theta\|^2 + C \sum_{i=1}^{n} (1 - y_i \theta^T x_i)_+.$$

---

19. Sub-gradiente della SVM

La hinge loss non è derivabile in $1-y_i\theta^T x_i = 0$, ma è convessa. Possiamo quindi usare il **sub-gradiente**.

19.1 Caso 1: punto ben classificato con margine sufficiente

Se

$$y_i \theta^T x_i > 1,$$

allora la hinge vale 0 e il contributo del punto alla loss è piatto. Il sub-gradiente è solo quello del termine di regolarizzazione:

$$\partial J(\theta) = \theta.$$

19.2 Caso 2: punto dentro il margine o classificato male

Se

$$y_i \theta^T x_i < 1,$$

allora

$$(1 - y_i \theta^T x_i)_+ = 1 - y_i \theta^T x_i.$$

Derivando rispetto a θ,

$$\nabla_\theta(1 - y_i\theta^T x_i) = -y_i x_i.$$

Quindi il sub-gradiente totale è

$$\partial J(\theta) = \theta - C y_i x_i.$$

19.3 Aggiornamento stocastico

Con learning rate γ, otteniamo:

- se $y_i\theta^T x_i > 1$,
$$\theta \leftarrow \theta - \gamma\theta;$$
- se $y_i\theta^T x_i < 1$,
$$\theta \leftarrow \theta - \gamma(\theta - C y_i x_i).$$

Cioè

$$\theta \leftarrow (1-\gamma)\theta + \gamma C y_i x_i.$$

Interpretazione

- il termine $(1-\gamma)\theta$ "ritira" i pesi verso zero;
- il termine $y_i x_i$ corregge l'errore di classificazione.

---

20. Kernel trick e argomento di rappresentazione

Supponiamo di mappare i dati in uno spazio di feature alto o infinito tramite $\Psi(x)$.

Nel nuovo spazio, il classificatore lineare è

$$f(x) = \theta^T \Psi(x).$$

L'idea chiave è che la soluzione ottima θ vive nello span dei dati trasformati.

20.1 Perché θ può essere scritto come combinazione dei dati

Scomponiamo θ in due parti:

$$\theta = \theta_{\parallel} + \theta_{\perp},$$

dove:

- $\theta_{\parallel}$ sta nello spazio generato dai vettori $\Psi(x_1), \ldots, \Psi(x_n)$;
- $\theta_{\perp}$ è ortogonale a quello spazio.

Per ogni training point x_i,

$$\theta^T \Psi(x_i) = \theta_{\parallel}^T \Psi(x_i) + \theta_{\perp}^T \Psi(x_i).$$

Ma $\theta_{\perp}$ è ortogonale a tutto lo span, quindi

$$\theta_{\perp}^T \Psi(x_i) = 0.$$

Dunque la classificazione dipende solo da $\theta_{\parallel}$.

Invece la norma si scompone come

$$\|\theta\|^2 = \|\theta_{\parallel}\|^2 + \|\theta_{\perp}\|^2.$$

Per minimizzare la norma, conviene mettere $\theta_{\perp} = 0$.

Conclusione

La soluzione ottima ha la forma

$$\theta = \sum_{i=1}^{n} \alpha_i \Psi(x_i).$$

20.2 Il kernel

Sostituendo nella funzione di decisione,

$$f(x) = \left(\sum_{i=1}^{n} \alpha_i \Psi(x_i) \right)^T \Psi(x) = \sum_{i=1}^{n} \alpha_i \langle \Psi(x_i), \Psi(x) \rangle.$$

Definiamo quindi il kernel

$$K(x_i, x) = \langle \Psi(x_i), \Psi(x) \rangle.$$

Otteniamo

$$f(x) = \sum_{i=1}^{n} \alpha_i K(x_i, x).$$

Interpretazione

Non serve conoscere esplicitamente $\Psi(x)$: basta saper calcolare $K(x, z)$.

---

21. Statistical Learning Theory: classi finite e sample complexity

Sia H una classe finita di classificatori. Vogliamo sapere quanti campioni servono per garantire che l'errore empirico sia vicino all'errore vero **uniformemente** su tutti gli $h \in H$.

21.1 Hoeffding per un classificatore fissato

Per un classificatore fissato h, l'errore empirico $\hat{R}(h)$ è la media di variabili Bernoulli indipendenti. Per Hoeffding,

$$P\big(|\hat{R}(h) - R(h)| > \varepsilon\big) \leq 2e^{-2n\varepsilon^2}.$$

21.2 Union bound su tutta la classe

A noi non basta controllare un solo h: vogliamo che il bound valga per **tutti** gli $h \in H$.

Usiamo quindi l'union bound:

$$P\left(\sup_{h \in H} |\hat{R}(h) - R(h)| > \varepsilon\right) \leq \sum_{h \in H} P\big(|\hat{R}(h) - R(h)| > \varepsilon\big).$$

Ogni termine è limitato da $2e^{-2n\varepsilon^2}$, quindi

$$P\left(\sup_{h \in H} |\hat{R}(h) - R(h)| > \varepsilon\right) \leq 2|H|e^{-2n\varepsilon^2}.$$

21.3 Ricavare la sample complexity

Se vogliamo che questa probabilità sia al più δ, imponiamo

$$2|H|e^{-2n\varepsilon^2} \leq \delta.$$

Prendiamo il logaritmo:

$$\log 2 + \log |H| - 2n\varepsilon^2 \leq \log \delta.$$

Equivalentemente,

$$2n\varepsilon^2 \geq \log \frac{2|H|}{\delta}.$$

Quindi basta prendere

$$n \geq \frac{1}{2\varepsilon^2} \log \frac{2|H|}{\delta}.$$

Conclusione

La sample complexity cresce solo **logaritmicamente** con la cardinalità della classe H.

---

22. VC dimension: esempi classici

La VC dimension di una classe H è il massimo numero di punti che H può **shatterare**, cioè etichettare in tutti i modi possibili.

22.1 Intervalli sulla retta: VC dimension = 2

Perché almeno 2

Prendiamo due punti $x_1 < x_2$. Un intervallo $[a, b]$ può realizzare tutte le etichettature:

- $--$: scegli intervallo vuoto;
- $+-$: prendi un intervallo che contiene solo x_1;
- $-+$: prendi un intervallo che contiene solo x_2;
- $++$: prendi un intervallo che contiene entrambi.

Quindi 2 punti sono shatterabili.

Perché non 3

Prendiamo tre punti ordinati $x_1 < x_2 < x_3$. Considera l'etichettatura

$$+, -, +.$$

Nessun intervallo singolo può includere x_1 e x_3 senza includere anche x_2.

Quindi 3 punti non sono shatterabili.

Conclusione

$$d_{VC} = 2.$$

22.2 Iperpiani in $\mathbb{R}^2$: VC dimension = 3

Perché almeno 3

Tre punti in posizione generale nel piano possono essere separati in tutti i modi da una retta.

Perché non 4

Prendiamo quattro punti in configurazione XOR. L'etichettatura alternata non è linearmente separabile.

Conclusione

Le rette in $\mathbb{R}^2$ hanno

$$d_{VC} = 3.$$

Più in generale, gli iperpiani in $\mathbb{R}^d$ hanno VC dimension $d + 1$.

---

23. Decision Trees: perché uno split non peggiora l'errore

Consideriamo una foglia l che contiene N_l punti, di cui N_l^+ positivi.

Definiamo

$$z_l = \frac{N_l^+}{N_l}.$$

L'impurità del nodo è una funzione $\psi(z_l)$, ad esempio:

- errore di classificazione;
- indice di Gini;
- entropia.

L'errore totale del nodo è

$$E(l) = N_l \psi(z_l).$$

Supponiamo di dividere il nodo in figlio sinistro L e figlio destro R.

23.1 La media della madre è combinazione convessa delle medie dei figli

Poiché

$$N_l = N_L + N_R, \qquad N_l^+ = N_L^+ + N_R^+,$$

abbiamo

$$\frac{N_l^+}{N_l} = \frac{N_L^+ + N_R^+}{N_l}.$$

Moltiplichiamo e dividiamo nei termini giusti:

$$\frac{N_l^+}{N_l} = \frac{N_L}{N_l}\frac{N_L^+}{N_L} + \frac{N_R}{N_l}\frac{N_R^+}{N_R}.$$

Se definiamo

$$\alpha = \frac{N_L}{N_l}, \qquad 1 - \alpha = \frac{N_R}{N_l},$$

allora

$$z_l = \alpha z_L + (1 - \alpha) z_R.$$

Quindi l'impurità della madre è valutata in una combinazione convessa delle impurità "grezze" dei figli.

23.2 Uso della concavità

Le funzioni di impurità standard sono **concave** in z. Per la concavità,

$$\psi(\alpha z_L + (1-\alpha) z_R) \geq \alpha \psi(z_L) + (1-\alpha)\psi(z_R).$$

Sostituendo le definizioni,

$$\psi\left(\frac{N_l^+}{N_l}\right) \geq \frac{N_L}{N_l}\psi\left(\frac{N_L^+}{N_L}\right) + \frac{N_R}{N_l}\psi\left(\frac{N_R^+}{N_R}\right).$$

Moltiplichiamo per N_l:

$$N_l\psi\left(\frac{N_l^+}{N_l}\right) \geq N_L\psi\left(\frac{N_L^+}{N_L}\right) + N_R\psi\left(\frac{N_R^+}{N_R}\right).$$

Cioè

$$E(\text{madre}) \geq E(\text{figlio sinistro}) + E(\text{figlio destro}).$$

Conclusione

Uno split non aumenta mai l'errore impurità totale.

---

24. Random Forests: perché aiutano

Un singolo albero è ad alta varianza: piccole variazioni nei dati possono cambiare molto la struttura appresa.

Le Random Forests riducono questa instabilità combinando:

1. **bootstrap** sui campioni;
2. **randomizzazione delle feature** ad ogni split;
3. **media / voto** di molti alberi.

Effetto bias-varianza

- il bias non aumenta troppo;
- la varianza si riduce parecchio.

Per questo le Random Forests generalizzano meglio di un singolo albero profondo.

---

25. Riassunto finale super-compatto per l'esame

Regressione e predittori ottimali

- loss quadratica $\Rightarrow$ media condizionata;
- loss assoluta $\Rightarrow$ mediana condizionata;
- classificazione binaria 0-1 $\Rightarrow$ classe a posteriori più probabile.

OLS

- minimizza $\|y - X\theta\|^2$;
- soluzione:
$$\hat{\theta} = (X^T X)^{-1} X^T y;$$
- residui ortogonali:
$$X^T (y - X\hat{\theta}) = 0;$$
- Hessiana:
$$X^T X \succeq 0;$$
- OLS è unbiased:
$$\mathbb{E}[\hat{\theta}] = \theta^*;$$
- varianza:
$$\mathrm{Var}(\hat{\theta}) = \sigma^2 (X^T X)^{-1}.$$

Ridge

- aggiunge $\lambda \|\theta\|^2$;
- riduce varianza;
- soluzione:
$$\hat{\theta}_{\text{ridge}} = (X^T X + \lambda I)^{-1} X^T y.$$

Logistic Regression

- nasce da Bernoulli + MLE;
- likelihood:
$$\prod_i p_i^{y_i} (1 - p_i)^{1 - y_i};$$
- objective equivalenti:
  - massimizzare log-likelihood;
  - minimizzare negative log-likelihood;
  - minimizzare cross-entropy.
- Hessiana negativa $\Rightarrow$ log-likelihood concavo.

Softmax

- gradiente:
$$\nabla_{\theta^{(k)}} L = \sum_i (y_i^{(k)} - \hat{P}^{(k)}(x_i)) \phi(x_i).$$

Perceptron

- converge se i dati sono linearmente separabili;
- numero di errori limitato da $R^2/(\gamma^*)^2$.

SVM

- massimizza il margine;
- soft margin $\Rightarrow$ hinge loss;
- kernel trick $\Rightarrow$ lavora con prodotti scalari in spazi di feature impliciti.

Statistical Learning Theory

- classi finite:
$$n \geq \frac{1}{2\varepsilon^2} \log \frac{2|H|}{\delta};$$
- la VC dimension misura la complessità della classe.

Decision Trees

- lo split non peggiora l'impurità grazie alla concavità di Gini / Entropia;
- le Random Forests riducono la varianza del singolo albero.

---

26. Osservazioni finali sulle confusioni più comuni

1. "Linear regression" non significa "retta nel grafico"

Significa **lineare nei parametri**. Posso usare feature come x, x^2, x^3 e ottenere curve non lineari in x, restando lineare in θ.

2. Logistic regression ha "due obiettivi"?

No: di solito è lo stesso obiettivo scritto in modi diversi.

$$\max \ell(\theta) \quad \Longleftrightarrow \quad \min -\ell(\theta).$$

3. Perché compare X^T in OLS?

Perché il residuo deve essere ortogonale allo spazio delle colonne di X, e questo si scrive

$$X^T(y - X\hat{\theta}) = 0.$$

4. Boosting riduce il bias o la varianza?

Principalmente **riduce il bias**, perché aggiunge modelli deboli in sequenza per correggere errori sistematici dei precedenti.

5. Bagging e Random Forest cosa riducono?

Principalmente **la varianza**, mediando molti modelli instabili.